

# Introduction et Révision des Concepts Essentiels des Séries Temporelles

## Chapitre 1

Économétrie des séries temporelles





## Ouvrages de référence

**Time Series Analysis**, James D. Hamilton

—

*Analysis of Financial Time Series*, Second Edition, Ruey S. Tsay

*Introductory Econometrics for Finance*, Second Edition, Chris Brooks

*Econometrics analysis*, Greene

*Introductory Econometrics*, Second Edition, J. M. Wooldridge

*Applied Time Series Analysis A Practical Guide to Modeling and Forecasting*, Terence C. Mills

*Introductory Time Series with R*, Paul S.P. Cowpertwait and Andrew V. Metcalfe

*Applied Time Series Econometrics*, Edited by Helmut Lütkepohl and Markus Krätzig

—

**Time Series Analysis and Its Applications With R Examples**, Third edition, Robert H. Shumway and David S. Stoffer

# 1. Introduction


**Série temporelle** : une séquence d'observations à travers le temps.

**Objectif** de l'analyse des séries temporelles : formuler un modèle statistique qui est une représentation bien spécifiée du processus inconnu qui a généré la série temporelle observée.

# Taux de chômage aux États-Unis

```
library(fredr) #https://fred.stlouisfed.org/docs/api/api_key.html
#fredr_set_key("votre clé perso")
library(tseries)
library(astsa)
library(xts)
library(quantmod)
```

```
USunrate = fredr(series_id = "UNRATE",
                  observation_start = as.Date("1948-01-01"),
                  observation_end = as.Date("2024-10-01"))
tsplot(USunrate$date, USunrate$value,
       ylab="Taux de chômage aux USA", xlab='')
abline(h = mean(USunrate$value), col = "red", lty = 2, lwd = 2)
legend("topright", legend = "Moyenne", col = "red", lty = 2, lwd = 2, bty = "n")
```



# Taux de chômage aux États-Unis (suite)

## Un oeil sur les données

```
head(USunrate)
```

```
## # A tibble: 6 x 5
##   date      series_id value realtime_start realtime_end
##   <date>    <chr>    <dbl> <date>      <date>
## 1 1948-01-01 UNRATE      3.4 2024-12-22 2024-12-22
## 2 1948-02-01 UNRATE      3.8 2024-12-22 2024-12-22
## 3 1948-03-01 UNRATE      4   2024-12-22 2024-12-22
## 4 1948-04-01 UNRATE      3.9 2024-12-22 2024-12-22
## 5 1948-05-01 UNRATE      3.5 2024-12-22 2024-12-22
## 6 1948-06-01 UNRATE      3.6 2024-12-22 2024-12-22
```

```
tail(USunrate)
```

```
## # A tibble: 6 x 5
##   date      series_id value realtime_start realtime_end
##   <date>    <chr>    <dbl> <date>      <date>
## 1 2024-05-01 UNRATE      4   2024-12-22 2024-12-22
## 2 2024-06-01 UNRATE      4.1 2024-12-22 2024-12-22
## 3 2024-07-01 UNRATE      4.3 2024-12-22 2024-12-22
## 4 2024-08-01 UNRATE      4.2 2024-12-22 2024-12-22
## 5 2024-09-01 UNRATE      4.1 2024-12-22 2024-12-22
## 6 2024-10-01 UNRATE      4.1 2024-12-22 2024-12-22
```

## Rendement du marché des titres du Trésor américain à échéance constante de 10 ans

```
IRT10 = fredr(series_id = "GS10",  
              observation_start = as.Date("2000-01-01"),  
              observation_end = as.Date("2024-10-01"),  
              frequency = "m")  
tsplot(IRT10$date, IRT10$value,  
       ylab="Taux de rendement", xlab='')
```





## Structure du cours

Modèles empiriques

Définir les concepts statistiques clés

Autocorrélation et autocorrélation partielle

Stationnarité et ergodicité

Processus stationnaires

Processus non stationnaires

Données empiriques

## 2. Modèles Empiriques

Sorties expérimentales causées par des entrées :

$$\underset{\text{[sortie]}}{y_t} = \underset{\text{[entrée]}}{f(z_t)} + \underset{\text{[perturbation]}}{\nu_t}$$

$y_t$  observé lorsque  $z_t$  est en entrée ;  $f(\cdot)$  mappe les entrées aux sorties ;  $\nu_t$  est une petite perturbation aléatoire.

Les mêmes sorties se répètent en répétant les expériences avec les mêmes entrées.

## Modèles Empiriques (suite)

Dans un modèle économétrique, cependant :

$$\underset{\text{[observée]}}{y_t} = \underset{\text{[explication]}}{g(z_t)} + \underset{\text{[reste]}}{\varepsilon_t}$$

$y_t$  décomposé en deux composantes :  $g(z_t)$  (partie expliquée) et  $\varepsilon_t$  (partie inexpliquée).

Toujours possible de décomposer  $y_t$  même si  $y_t$  ne dépend pas de  $g(z_t)$ .

## Modèles Empiriques (suite)

En économétrie :

$$\varepsilon_t = y_t - g(z_t)$$

Les modèles peuvent être conçus par la sélection de  $z_t$ .

Les critères de conception doivent être analysés : conduiront à la notion de modèle congruent.

Les modèles congruents successifs doivent expliquer les précédents : concept d'englobement - par lequel le progrès est réalisé.

## Modèles de Séries Temporelles

Processus autorégressifs univariés :

$$y_t = \alpha y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

WN - bruit blanc : processus à moyenne nulle, variance constante

Séries temporelles multiples :

$$\mathbf{y}_t = \mathbf{A} \mathbf{y}_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(\mathbf{0}, \mathbf{\Sigma})$$

e.g. VAR :

$$\begin{bmatrix} y_{1,t} \\ y_{2,t} \end{bmatrix} = \begin{bmatrix} \alpha_{11} & \alpha_{12} \\ \alpha_{21} & \alpha_{22} \end{bmatrix} \begin{bmatrix} y_{1,t-1} \\ y_{2,t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix}$$

$$\begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{bmatrix} \sim \text{WN} \left( \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{bmatrix} \right)$$

## Modèles de Séries Temporelles (suite)

Modèle autorégressif à retard distribué (ADL) :

$$y_t = \alpha_1 z_t + \alpha_2 y_{t-1} + \alpha_3 z_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2)$$

### 3. Données de Séries Temporelles

Une **série temporelle** est une variable aléatoire observée de manière répétée dans le temps, indexée par  $t$ .

Une **variable aléatoire** dans le contexte des séries temporelles est une fonction  $Y_t$  qui associe une valeur réelle à chaque instant  $t$  dans un ensemble d'indices temporels  $\mathcal{T}$  (par exemple, des jours, mois, ou années).

$Y_t : \Omega \rightarrow \mathbb{R}$ , où  $\Omega$  est l'ensemble des résultats possibles, et  $t \in \mathcal{T}$ .

À chaque instant  $t$ ,  $Y_t$  représente une observation aléatoire, influencée par des facteurs incertains.

Contrairement à des variables indépendantes, les variables aléatoires  $Y_t$  dans une série temporelle présentent souvent des dépendances temporelles (un état passé influence les états futurs).

**Exemple** :  $Y_t$  pourrait représenter la température quotidienne d'une ville, la valeur d'une action boursière, ou le nombre de ventes quotidiennes d'un produit.

## Processus Stochastiques

Un **processus stochastique** est une séquence ordonnée de **variables aléatoires**  $\{y_t(\omega), \omega \in \Omega, t \in \mathcal{T}\}$  telle que pour chaque  $t \in \mathcal{T}$ ,  $y_t(\omega)$  est une variable aléatoire sur  $\Omega$ , et pour chaque  $\omega \in \Omega$ ,  $y_t(\omega)$  est une réalisation du processus stochastique sur l'ensemble d'indices  $\mathcal{T}$ .

Une série temporelle  $\{y_t\}_{t=1}^T$  est une réalisation particulière  $\{y_t\}_{t \in \mathcal{T}}$  d'un processus stochastique, une fonction  $\mathcal{T} \rightarrow \mathbb{R}$  où  $t \rightarrow y_t(\omega)$ .

Le processus stochastique sous-jacent est dit avoir généré la série temporelle  $y_1(\omega), y_2(\omega), \dots, y_T(\omega)$ , notée  $\{y_t\}$ .



## Caractéristiques des Séries Temporelles

**Persistence** - liée aux observations précédentes

**Retour à la moyenne** - retourne aux niveaux d'équilibre

**Autocorrélation** - pour décrire la dépendance temporelle

La distribution conjointe de  $(y_t, y_{t-1}, \dots, y_{t-h})$  est caractérisée par la

**Fonction d'Autocovariance** :

$$\begin{aligned}\gamma_t(h) &= \text{cov}(y_t, y_{t-h}) \\ &= E[(y_t - \mu_t)(y_{t-h} - \mu_{t-h})] \\ &= \int \cdots \int (y_t - \mu_t)(y_{t-h} - \mu_{t-h}) f(y_t, \dots, y_{t-h}) dy_t \cdots dy_{t-h}\end{aligned}$$

où  $\mu_t = E[y_t] = \int y_t f(y_t) dy_t$  est la moyenne inconditionnelle de  $y_t$ .

L'indice  $t$  capture la dépendance temporelle de l'autocovariance.

## Moments d'Échantillon

Moyenne :

$$\bar{y} = \frac{1}{T} \sum_{t=1}^T y_t$$

Fonction d'Autocorrélation d'Échantillon (ACF) :

$$\rho_t(h) = \frac{\sum_{t=h+1}^T (y_t - \bar{y})(y_{t-h} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

## Moments d'Échantillon (suite)

### Fonction d'Autocorrélation Partielle (PACF) :

$$r_{ij.k} = \text{corr}(y_t, y_{t-h} | y_{t-1}, \dots, y_{t-h+1})$$

Dans le cas à 3 variables :

$$r_{02.1} = \frac{r_{02} - r_{01}r_{12}}{\sqrt{1 - r_{01}^2} \sqrt{1 - r_{12}^2}}$$

où

$$r_{01} = \text{corr}(y_t, y_{t-1}) = \text{corr}(y_{t-1}, y_{t-2}) = r_{12} = \rho(1)$$

$$r_{02} = \text{corr}(y_t, y_{t-2}) = \rho(2)$$

Donc :

$$r_{02.1} = \frac{\rho(2) - \rho^2(1)}{1 - \rho^2(1)}$$

sous moyenne et variance constantes.

## Moments d'Échantillon (suite)

### Processus AR(p) :

$r_{ij.k} = 0$  pour  $h > p$

Indépendance conditionnelle

Pour  $h = 2$  :

$$r_{02.1} = \text{corr}(y_t, y_{t-2} | y_{t-1}) = 0$$

si

$$f(y_t, y_{t-2} | y_{t-1}) = f(y_t | y_{t-1}) f(y_{t-2} | y_{t-1}).$$

Donc :

$$\begin{aligned} f(y_t, y_{t-2} | y_{t-1}) &= f(y_t | y_{t-1}, y_{t-2}) f(y_{t-2} | y_{t-1}) \\ &= f(y_t | y_{t-1}) \end{aligned}$$

**Processus de Markov** – la distribution conditionnelle de  $y_t$  étant donnée tout le passé  $y_{t-1}, y_{t-2}, \dots$ , dépend seulement du passé immédiat  $y_{t-1}$ .

## Distributions des Moments d'Échantillon

Pour  $y_t \sim \text{IID}(\mu, \sigma^2)$  :

$$\sqrt{T}\bar{y} \rightarrow N(\mu, \sigma^2)$$

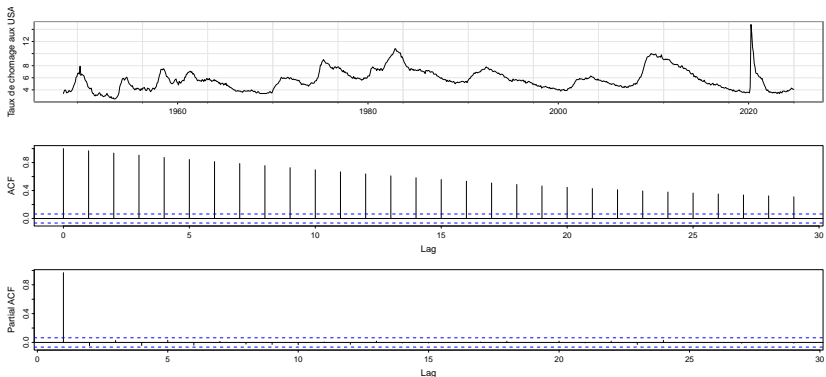
$$\sqrt{T}\hat{\rho}_h \rightarrow N(0, 1)$$

$$\sqrt{T}\hat{r}_{ij.k} \rightarrow N(0, 1)$$

où IID - indépendamment et identiquement distribué.


## ACF/PACF pour le taux de chômage aux USA

```
par(mfrow=c(3,1))
tsplot(USunrate$date, USunrate$value,
       ylab="Taux de chômage aux USA", xlab='')
acf(USunrate$value, main = "ACF USunrate")
pacf(USunrate$value, main = "PACF USunrate")
```



## ACF/PACF pour $\Delta$ taux de chômage aux USA

```
par(mfrow=c(3,1))
tsplot(USunrate$date[-1], diff(USunrate$value),
       ylab=expression(Delta ~ "Taux de chômage aux USA"), xlab='')
acf(diff(USunrate$value), main = "")
pacf(diff(USunrate$value), main = "")
```



## Stationnarité

Une série temporelle  $\{y_t\}$  est **faiblement stationnaire** ou stationnaire en covariance si les premiers et seconds moments du processus existent et sont invariants dans le temps.

$$E[y_t] = \mu < \infty \quad \forall t \in T$$

$$E[(y_t - \mu)(y_{t-h} - \mu)] = \gamma(h) < \infty \quad \forall t, h$$

La stationnarité implique  $\gamma_t(h) = \gamma_t(-h) = \gamma(h)$ .

—

Une série temporelle  $\{y_t\}$  est **strictement stationnaire** si, pour toute valeur de  $h_1, h_2, \dots, h_n$ , la distribution jointe de  $y_t, y_{t+h}, \dots, y_{t+hn}$  dépend uniquement des intervalles  $h_1, h_2, \dots, h_n$  et non de  $t$  :

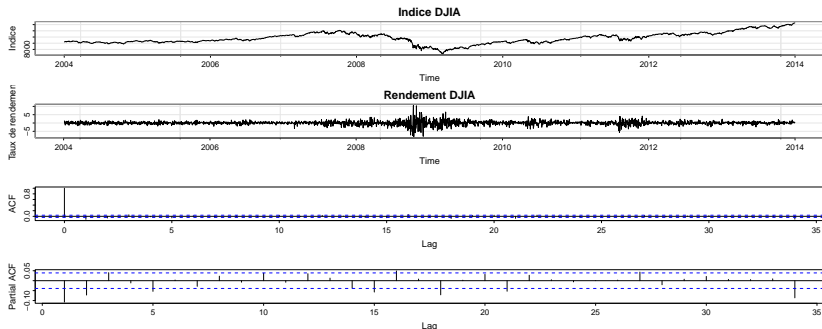
$$f(y_t, y_{t+h}, \dots, y_{t+hn}) = f(y_\tau, y_{\tau+h}, \dots, y_{\tau+hn}) \quad \forall t, \tau$$

La stationnarité stricte implique que tous les moments sont invariants dans le temps.



## Dow Jones Industrial Average

```
DJI = getSymbols("^DJI", src = "yahoo", from = "2004-01-01",  
                to = "2014-01-01", auto.assign = FALSE)  
djia = Cl(DJI)  
djar = 100 * diff(log(djia))[-1] # [-1] retire 1 observation  
par(mfrow=c(4,1))  
tsplot(index(DJI), djia, main="Indice DJIA", ylab="Indice")  
tsplot(index(DJI)[-1], djar, main="Rendement DJIA", ylab="Taux de rendement")  
acf(djar, main = '')  
pacf(djar, main = '')
```



## Ergodicité

L'ergodicité concerne l'information qui peut être dérivée d'une moyenne temporelle sur la moyenne commune à un point dans le temps. (La loi des grands nombres faible n'est pas applicable car la série temporelle observée représente une seule réalisation du processus stochastique).

Soit  $\{y_t(\omega), \omega \in \Omega, t \in T\}$  un processus faiblement stationnaire, tel que  $E[y_t(\omega)] = \mu < \infty$  et  $E[(y_t(\omega) - \mu)^2] = \sigma_y^2 < \infty, \forall t$ , et

$$\bar{y}_T = \frac{1}{T} \sum_{t=1}^T y_t$$

est la moyenne temporelle.

Si  $\bar{y}_T \xrightarrow{P} \mu$  lorsque  $T \rightarrow \infty$ ,  $\{y_t\}$  est ergodique pour la moyenne.

Ergodicité - indépendance asymptotique

Stationnarité - invariance temporelle

## Ergodicité (suite)

L'ergodicité nécessite que la mémoire d'un processus stochastique s'estompe de sorte que la covariance entre des observations de plus en plus distantes converge vers 0 suffisamment rapidement.

Pour les processus stationnaires,

$$\sum_{h=0}^{\infty} |\gamma(h)| < \infty$$

est suffisant pour assurer l'ergodicité.

Ergodicité pour les seconds moments :

$$\hat{\gamma}(h) = \frac{1}{T-h+1} \sum_{t=h+1}^T (y_t - \mu)(y_{t-h} - \mu) \xrightarrow{p} \gamma(h)$$

## 4. Processus de Base

### Bruit blanc

Un processus de bruit blanc est un processus faiblement stationnaire qui a une moyenne nulle et est non corrélé dans le temps :

$$u_t \sim \text{WN}(0, \sigma^2)$$

$\{u_t\}$  est WN si  $E[u_t] = 0$ ,  $E[u_t^2] = \sigma^2 < \infty$ , et  $E[u_t u_{t-h}] = 0$  où  $h \neq 0$  et  $t - h \in T$  pour tout  $t \in T$ .

Si la variance constante est relâchée à  $E[u_t^2] < \infty$ ,  $\{u_t\}$  est un processus de bruit blanc faible.





Si  $\{u_t\}$  est normalement distribué, c'est un processus de bruit blanc gaussien :

$$u_t \sim \text{NID}(0, \sigma^2)$$

Normalité  $\Rightarrow$  stationnarité stricte et indépendance sérielle.

## Génération de bruits blancs gaussiens centrés réduits

```
par(mfrow=c(2,2))  
tsplot(rnorm(30)); tsplot(rnorm(100))  
tsplot(rnorm(1000)); tsplot(rnorm(5000))
```



## Processus IID

Un processus  $\{u_t\}$  avec des variables indépendantes et identiquement distribuées est IID :

$$u_t \sim \text{IID}(0, \sigma^2)$$

## Martingales

Le processus stochastique  $\{y_t\}$  est une martingale par rapport à un ensemble d'informations  $I_{t-1}$  des données  $\{I_{t-1} = y_{t-1}, \dots, y_1\}$ , réalisé à  $t - 1$ , si  $E[|y_t|] < \infty$  et l'espérance conditionnelle  $E[y_t | I_{t-1}] = y_{t-1}$ .

Le processus  $\{u_t = y_t - y_{t-1}\}$  avec  $E[|u_t|] < \infty$  et  $E[u_t | I_{t-1}] = 0$  est une séquence de différences de martingale (MDS).

## Innovations

Une innovation  $\{u_t\}$  contre un ensemble d'informations  $I_{t-1}$  est un processus dont la densité  $f(u_t|I_{t-1})$  ne dépend pas de  $I_{t-1}$ .

$\{u_t\}$  est une innovation de moyenne contre un ensemble d'informations  $I_{t-1}$  si  $E[u_t|I_{t-1}] = 0$ .

Une innovation  $\{u_t\}$  doit être  $WN(0, \sigma^2)$  si  $I_{t-1}$  contient l'historique  $(U_{t-1} = u_0, u_1, \dots, u_{t-1})$  de  $u_t$ , mais pas inversement.

Par conséquent, une innovation doit être une MDS.



## Processus Intégrés

Les processus intégrés peuvent être rendus stationnaires par différenciation.

Un processus stochastique  $\{y_t\}$  est une marche aléatoire si :

$$y_t = y_{t-1} + u_t \quad \text{pour } t > 0 \quad \text{et } y_0 = 0$$

où  $u_t \sim \text{IID}(0, \sigma^2)$ ,  $\forall t > 0$ .

Une marche aléatoire est non stationnaire et donc non ergodique :

$$y_t = y_0 + \sum_{s=1}^t u_s \quad \forall t > 0.$$

La moyenne est invariante dans le temps :

$$\mu = E[y_t] = E \left[ y_0 + \sum_{s=1}^t u_s \right] = y_0 + \sum_{s=1}^t E[u_s] = 0$$

## Processus Intégrés (suite)

Mais les seconds moments divergent. La variance est :

$$\gamma_t(0) = E[y_t^2] = E \left[ \left( y_0 + \sum_{s=1}^t u_s \right)^2 \right] = \sum_{s=1}^t \sigma^2 = t\sigma^2$$

Les autocovariances sont :

$$\gamma_t(h) = E[y_t y_{t-h}] = E \left[ \left( y_0 + \sum_{s=1}^t u_s \right) \left( y_0 + \sum_{k=1}^{t-h} u_k \right) \right] = (t-h)\sigma^2$$

pour tout  $h > 0$ .

## Processus Intégrés (suite)

La fonction d'autocorrélation est :

$$\rho_t(h) = \frac{\gamma_t(h)}{\gamma_t(0)\gamma_{t-h}(0)} = \frac{(t-h)\sigma^2}{t\sigma^2(t-h)\sigma^2} = 1 - \frac{h}{t}$$


pour tout  $h > 0$ .

Si un processus stochastique doit être différencié  $d$  fois pour atteindre la stationnarité, il est intégré d'ordre  $d$ , ou  $I(d)$ .

Une marche aléatoire est  $I(1)$  et les processus stationnaires sont  $I(0)$ .

## Marche aléatoire avec et sans drift

```
set.seed(154) # pour la reproductibilité
w = rnorm(200); x = cumsum(w) # deux commandes en une ligne
wd = w + .2;    xd = cumsum(wd)
par(mfrow=c(1,1))
tsplot(xd, ylim=c(-5,55), main="Marche aleatoire", ylab='')
lines(x, col=4)
clip(0,200,0,50)
abline(h=0, col=4, lty=2)
abline(a=0, b=.2, lty=2)
```



Marche aléatoire,  $\sigma_w = 1$ , avec dérive  $y_0 = 0.2$  (ligne noire), sans dérive,  $y_0 = 0$  (ligne bleue), et une ligne droite pointillée avec une pente de 0.2.